

DCI-VTON Tabanlı Sanal Giyim Sistemlerinde El Bölgesi Görsel Kalitesinin LoRA ile Artırılması

Enhancing Hand Region Visual Quality in DCI-VTON Based Virtual Try-On Systems Using LoRA

Beyza Nur Özben¹, Elif Altunsu², Oğuz Emre Kural³

Bilgisayar Mühendisliği Bölümü
Ondokuz Mayıs Üniversitesi, Samsun

¹nur.ozben@bil.omu.edu.tr, ²elif.altunsu@bil.omu.edu.tr, ³oguz.kural@bil.omu.edu.tr

Özetçe

Bu çalışma, moda teknolojileri alanında giderek yaygınlaşan Sanal Deneme (Virtual Try-On, VTON) sistemlerinde yüksek kaliteli görseller üretme potansiyeliyle dikkat çeken difüzyon tabanlı bir model üzerine inşa edilmiştir. Model çıktılarında özellikle el bölgelerinde gözlemlenen deformasyonlar hedef alınarak, bu bölgelerdeki görünümün daha doğal ve gerçekçi hale getirilmesi amaçlanmıştır. Deneyler sınırlı verilerle gerçekleştirilmiştir. Modelin tamamını yeniden eğitmek yerine, Düşük Sıralamalı Adaptasyon (Low-Rank Adaptation, LoRA) yalnızca dikkat mekanizmalarına entegre edilmiştir, görsel kalitede önemli iyileştirmeler sağlanmıştır. Bu entegrasyon, VTON sistemlerinin daha gerçekçi ve kullanıcı dostu hale getirilmesine katkı sunmaktadır.

Abstract

This study is built upon a diffusion-based model, which has attracted attention for its potential to generate high-quality images in Virtual Try-On (VTON) systems, a technology that is becoming increasingly prevalent in the field of fashion technologies. It specifically targets the deformations observed in the hand regions of the model outputs, aiming to make these areas appear more natural and realistic. The experiments were conducted with limited data. Instead of retraining the entire model, Low-Rank Adaptation (LoRA) was integrated solely into the attention mechanisms, leading to significant improvements in visual quality. This integration contributes to making VTON systems more realistic and user-friendly.

1. Giriş

Günümüzde tekstil sektörü, büyük ölçüde çevrimiçi alışveriş sitelerinden satışa yönelmiştir. Ancak tüketicilerin kıyafetleri uygun manken, ürün ve kalıpla deneyememesi zaman, maliyet ve kullanıcı deneyimi açısından önemli kayıplara yol açabilmektedir. Bahsi geçen tüm kayıpları en aza indirmek adına VTON teknolojisi geliştirilmiştir.

VTON sistemleri; derin öğrenme, bilgisayarlı görü, Artırılmış Gerçeklik (Augmented Reality, AR) dahil olmak üzere birçok teknolojiyi bir araya getirmektedir. Bu sayede kullanıcılar, kıyafet, makyaj malzemesi, aksesuar veya mobilya gibi ürünleri fiziksel deneme yapmadan dijital ortamda üzerlerinde veya kullanılabilecek ortamda nasıl bir görünüme sahip olacağına dair fikir edinebilmektedir. Gerçeğe yakın temsiller hem üreticiler hem de tüketiciler açısından daha bilinçli alışveriş kararları alınmasına katkı sağlamaktadır.

Kullanıcılar fiziksel olarak mağazaya gitmeden ürünleri dijital manken üzerinde deneyimleyerek zamandan tasarruf etmektedir. Bunun yanı sıra tüketicilerin çevrimiçi alışverişte karar verme sürecini kolaylaştırır ve iade oranlarını azaltarak e-ticaret sistemlerinin verimliliğine katkı sağlar. Küresel ölçekte farklı kullanıcı profillerine uygulanabilirlik sunan bu yöntem, ürün üretim ve iade süreçlerini azaltarak karbon ayak izini düşürür. Günümüzde VTON teknolojisi için birçok çalışma mevcuttur. Bu çalışmalarda, görsel üretimi amacıyla genellikle iki tür yapay sinir ağı tercih edilmektedir: Çekişmeli Üretici Ağlar (Generative Adversarial Networks, GANs) ve Difüzyon Modelleri [1], [2]. VTON alanında görsel üretim süreçlerinde difüzyon modelleri, GAN'lara kıyasla daha çeşitli ve yüksek kaliteli çıktılar ürettikleri için giderek daha fazla tercih edilmektedir.


Sanal Deneme alanında GAN ve difüzyon modellerinin kullanıldığı çalışmalar karşılaştırıldığında, difüzyon temelli yaklaşımların GAN tabanlı modellere kıyasla daha etkili ve işlevsel sonuçlar ürettiği gözlemlenmiştir. GAN'ların büyük ölçekli veri üretiminde karşılaştığı sınırlı çeşitlilik ve düşük doğruluk gibi sorunlara, difüzyon modelleri daha başarılı çözümler sunmuştur. Üretim süreci daha maliyetli olsa da, difüzyon modelleri daha kararludur ve GAN'lara kıyasla eğitilmeleri daha az kaynak gerektirmektedir. Kıyafet hizalamasında yüksek doğruluk sunan ve açık kaynak olarak erişilebilen ilgili proje, bu çalışmanın temelini oluşturmuştur. Bu doğrultuda, Sanal Kıyafet Denemesi için Koşullu Difüzyon Tabanlı Onarma (Diffusion-based Conditional Inpainting for Virtual Try-On, DCI-VTON) modeli tercih edilmiştir [3].

2. Yöntem

DCI-VTON, yüksek kaliteli sanal giydirmeye çıktılar üretmek amacıyla geliştirilen difüzyon tabanlı bir görüntü tamamlama (inpainting) modelidir. Model; kullanıcı görüntüsü, hedef kıyafet, poz bilgisi gibi çoklu koşullara bağlı olarak çalışmakta ve görünüm aktarımında doğal, yüksek çözünürlüklü sonuçlar üretmektedir. Bununla birlikte, model özellikle el gibi ince detaylara sahip bölgelerde deformasyonlar oluşturmakta ve bu durum genel görsel kaliteyi düşürmektedir. Bu sorunun giderilmesi amacıyla, son yıllarda yaygın olarak kullanılan LoRA (Low-Rank Adaptation) tekniği çözüm olarak önerilmiştir [4].

2.1. Difüzyon Modeli

Görüntü üretim modelleri, son yıllarda hızla gelişen bir araştırma alanı hâline gelmiştir. Otokodlayıcı (AutoEncoder), Varyasyonel Otokodlayıcı (Variational Autoencoder, VAE) ve GAN gibi yöntemler aracılığıyla rastgele gürültüden gerçekçi görseller üretmek mümkün olmuştur. Modeller genellikle tek adımlı dönüşüm gerçekleştirdiğinden, üretim sürecindeki küçük hatalar doğrudan nihai çıktıya yansımakta ve görsellerde yapaylık ya da yapısal bozulmalara yol açabilmektedir. Bu yöntemler ile yüksek kaliteli görüntüler üretilebilse de, görselin tek bir adımda oluşturulması yerine çok aşamalı bir üretim sürecinin tercih edilmesi daha sağlam sonuçlar doğurabilmektedir. Böylelikle, üretim sürecinde oluşan hatalar modelin sonraki aşamalarında telafi edilebilmekte ve çıktı kalitesi artırılabilir. Bu yaklaşıma dayalı olarak geliştirilen difüzyon modelleri, çok aşamalı üretim süreci sayesinde daha kararlı ve gerçekçi görseller sunmaktadır. Her adımda bir öncekinin sonucu iyileştirilir ve geliştirilir. Bu sayede süreç boyunca ortaya çıkan hatalar gittikçe düzeltilebilir.



Şekil 1: Difüzyonun Genel Çalışma Mantığı

Modelin ana fikri görsele eklenen gürültüyü adım adım azaltmak ve sonucunda tamamen yok etmektir (denoising). Gürültü görüntüsü (noise image), birçok adımda hedef resme eklenen bozulma (örneğin, Gauss gürültüsü) olarak tanımlanabilir. Modelin amacı, gürültünün dağılımını öğrenerek gürültüyü etkili bir şekilde azaltmaktır. Her bir adımın çıktısı bir sonraki adımın girdisi olarak kullanılır ve son aşamada yüksek kaliteli görsel elde edilene kadar gürültü azaltma işlemi sürdürülür. Bu modellerinin eğitimi İleri difüzyon (forward diffusion) ve geri difüzyon (reverse diffusion) olmak üzere iki temel aşamayı içermektedir. İleri difüzyon aşamasında, gerçek bir görsele adım

adım gürültü eklenerek tamamen bozulmuş, rastgele bir görüntü elde edilir. Bu süreçte adım sayısı, eklenecek gürültü miktarı, gürültü türü ve dağılım parametreleri gibi faktörler önceden belirlenir. Geri difüzyon aşamasında ise model, bu gürültülü görüntüyü analiz ederek orijinal görüntüyü yeniden tahmin etmeyi öğrenir. Hedef, rastgele gürültüyle başlanan süreci tersine çevirerek gerçekçi ve yüksek çözünürlüklü bir görsel üretmektir. Adım adım uygulaması Şekil 1’de verilmiştir.

2.1.1. U-Net

Difüzyon modellerinin temel bileşenlerinden birisi U-net mimarisidir. U-Net, ilk olarak “U-Net: Biyomedikal Görüntülerin Bölümlendirilmesi için Evrimsel Ağlar” başlıklı çalışmada tanıtılan ve yaygın olarak kullanılan bir derin öğrenme mimarisidir [5]. Bu ağ, yüksek hız ve doğruluk sağlarken, veriyi daha etkili kullanacak şekilde tasarlanmıştır. Daralan yol-genişleyen yol (encoder-decoder) tipinde mimarisi olan Evrimsel Sinir Ağı (Convolutional Neural Network, CNN) çeşidi olarak sınıflandırılır.

“U” şeklindeki mimarisinden kaynaklı U-Net olarak adlandırılmıştır. Modelin sol tarafında yer alan encoder bileşeni, giriş görüntüsünden hiyerarşik özellikleri çıkarmakla görevlidir. Sağ tarafta yer alan decoder ise, kodlanmış veriyi çözer ve daralan yoldan gelen bilgileri atlama bağlantıları (skip connections) aracılığıyla segmentasyon haritası oluşturur. Her encoder katmanından elde edilen çıktı, ilgili decoder katmanına doğrudan aktarılır ve böylece detay kaybı azaltılır. Bu mimari, özellikle sınırlı veri kümeleriyle çalışırken dahi detaylı uzamsal bilgileri koruyarak daha başarılı segmentasyon sonuçları elde etmeye olanak tanımaktadır.

2.2. VTON Çeşitleri


Görüntü tabanlı VTON, uzun süredir araştırmacıların ilgi odağında olan, yüksek potansiyele sahip ancak gerçekleştirilmesi karmaşık bir süreçtir. Difüzyon tabanlı sanal deneme çalışmalarından DCI-VTON, bükme (warping) işlemine ihtiyaç duyar. Gizli Difüzyon Metinsel-Tersine Çevrim ile Geliştirilmiş Sanal Kıyafet Deneme (Latent Diffusion Textual-Inversion Enhanced Virtual Try-On, LaDI-VTON) metin tersine çevirme (textual inversion) yöntemiyle geliştirilmiş ilk sanal deneme modelidir [6]. Gizli Difüzyon Modeli (Latent Diffusion Model, LDM) ve bükülmüş girişi koşullandırmak için, LaDI-VTON giysinin görsel özelliklerini Karşıt Dil-Görüntü Ön Eğitimi (Contrastive Language-Image Pre-training, CLIP) belirteç (token) gömme alanına aktarmak üzere özellikle metinsel tersine çevirme yöntemini kullanmıştır [7]. DCI-VTON, bükme modülünden (warping module) yararlanarak yayılma modelinin gelişimini verimli bir şekilde yönlendiren, örnek tabanlı (exemplar-based) bir tamamlama yöntemi önermiştir [3]. Bu yöntem, yayılma modelinin gücünden etkili bir şekilde yararlanır ve warping module’ün eklenmesi, gerçekçi ve üstün sanal giydirmeye sonuçlarının elde edilmesine katkı sağlar. StableVTON, önceden eğitilmiş modelin güçlü üretim yeteneklerinden yararlanırken giysi detaylarını korumak amacıyla sıfır çapraz dikkat blokları (zero cross-attention blocks) kullanmaktadır [8].

Geçmiş çalışmaları iyileştirmek ve ilerletmek amacıyla, yakın zamanda pek çok difüzyon tabanlı proje geliştirilmiştir. Kontrollü Sanal Kıyafet Deneme için Kıyafet Birleştirme Tabanlı Gizli Difüzyon (Outfitting Fusion based Latent Diffusion for Controllable Virtual Try-On, OOTDiffusion), giysi özelliklerini detaylı öğrenebilmesi adına önceden eğitilmiş (pre-trained) LDM yetilerini kuvvetlendirerek bir giydirmе UNet'i (outfitting UNet) tasarlamıştır [9]. Çoklu Görünümlü Sanal Deneme (Multi-View Virtual Try-On, MV-VTON), ön ve arka giysi görünümünü dikkate alarak, difüzyon tabanlı üretici modeller aracılığıyla yüksek kaliteli görüntü üretimi gerçekleştirir [10]. Yöntem, küresel ve yerel giysi özelliklerini sırasıyla zorlu (hard) ve kolay (soft) seçim mekanizmalarıyla analiz ederken, giysi ve vücut özelliklerini hizalamak için ortak dikkat blokları (co-attention blocks) kullanır. Ayrıca, Çok Görünümlü Giysi (Multi-View Garment, MVG) adlı yeni bir veri setiyle eğitilmiştir. Doğal Ortamda Gerçek Sanal Deneme İçin Difüzyon Modellerinin Geliştirilmesi (Improving Diffusion Models for Authentic Virtual Try-On in the Wild, IDM-VTON) temiz ve kontrollü verilerle sınırlı önceki yöntemlerin aksine, gerçek dünyada çekilmiş karmaşık görüntülerde daha otantik sonuçlar üretebilen difüzyon tabanlı bir VTON modeli sunar [11]. CatVTON, geleneksel difüzyon tabanlı yöntemlerin aksine, karmaşık ön işleme adımlarını (örneğin poz tahmini, insan segmentasyonu veya metin açıklamaları) tamamen ortadan kaldırarak yalnızca kişi ve kıyafet görüntülerinin uzamsal olarak birleştirilmesi (concatenation) yoluyla modellemeyi mümkün kılar [12]. Model, yalnızca 49.57M eğitilebilir parametre ile çalışmasına rağmen, hem niteliksel hem de niceliksel olarak güçlü sonuçlar elde etmiştir.

2.3. DCI-VTON

DCI-VTON, warping module'ünü temel olarak difüzyon sürecini örnek temelli (exemplar-based) bilgiler doğrultusunda yönlendiren etkili bir tamamlama yöntemi geliştirmiştir. Bu yaklaşım, difüzyon modelinin üretim gücünden etkili biçimde yararlanmakta ve fazladan entegre edilen warping module, gerçekçi ve yüksek kaliteli sanal giydirmе sonuçlarının elde edilmesine önemli katkı sağlamaktadır. Her ne kadar modelin difüzyon mimarisi yüksek kaliteli görüntü üretiminde başarılı bir yapı sunsa da görseldeki kıyafeti koşul olarak verip görüntü tamamlama (inpainting) yöntemi ile eğitmek, kıyafetin detaylarının korunması açısından yetersiz kalabilmektedir. Bu sorunun üstesinden gelebilmek amacıyla DCI-VTON, exemplar-based görüntü tamamlama yaklaşımı önermektedir [3].


Exemplar-based yöntem, warping module artırarak difüzyon modeline daha etkili görsel üretme için rehberlik eder. Warping module, kıyafetlerde içsel bir işlem yaparak kıyafetin yerel detaylarını algılamayı sağlamaktadır. Bir sonraki aşamada, bükülen kıyafetler ile kıyafet-agnostik (clothes-agnostic) kişi görseli eşlenir ve üzerine difüzyon modeli girdisi olarak gürültü eklenmektedir. Buna ek olarak bükülmüş kıyafetler her denoising adımı için yerel koşul (local condition) olarak kullanılmaktadır. Öte yandan, kıyafet görseli ile mankenin vücut görseli doğru şekilde birleştirilirken, bu iki görüntü arasındaki uyumu ve hizayı kurmak için dikkat (attention) mekanizmaları kullanılmaktadır. Söz konusu mekanizmalar, kıyafet bileşenlerinin hedef vücut bölgeleriyle konumsal olarak



Şekil 2: DCI-VTON Mimarisi

eşleştirilmesini sağlayan yapısal hizalama bilgisini öğrenmeyi amaçlamaktadır. Böylelikle, sonuç çıktısının olabildiğince detay taşıdığından emin olunmaktadır. Tüm bu süreçler Şekil 2'de görselleştirilmiştir [3].

DCI-VTON, efektif şekilde difüzyon modelinin gücünden faydalanır ve warping module'ün birleşimi, kaliteli ve detaylı çıktı üretimine yardımcı olur. Özetle DCI-VTON'un temel yeniliği, kıyafetin kullanıcı üzerine giydirilmesini bir görüntü tamamlama problemi olarak ele alması ve bu işlemi bir difüzyon süreci aracılığıyla kademeli olarak gerçekleştirmesidir. Özellikle kıyafetin vücuda doğal bir şekilde yerleşmesini sağlayan görünüm akışı (appearance flow) mekanizması ile önceki yöntemlere kıyasla daha gerçekçi ve kesintisiz görseller elde edilmiştir. Şekil 3, DCI-VTON'un çalışma prensibini özetlemektedir: kıyafet hedef kişiye hizalanmakta, gürültü enjeksiyonu uygulanmakta ve bu girdiler difüzyon modelinde işlenerek hizalı çıktılar yeniden üretilmektedir [3].




Şekil 3: DCI-VTON Çalışma Şekli

2.4. LoRA


Parametre Verimli İnce Ayar (Parameter-Efficient Fine-Tuning, PEFT), kullanılan parametre sayısını azaltarak ön eğitilmiş modeli hafifleten destekleyici yaklaşımdır [13]. Var olan model parametrelerinin tamamının güncellenmesi gerekmez. Bu da bir modelin parametre güncellenmesi ve yeniden eğitimi açısın-

dan değerlendirildiğinde, zamandan önemli ölçüde tasarruf sağlanır. Büyük Dil Modelleri'nin (Large Language Models, LLM) yeniden eğitime kolaylaştırıcı bir destek olarak ortaya çıkan PEFT'in onlarca geliştirilmiş yöntemi mevcuttur. LoRA, PEFT'in en yaygın yaklaşımlarındandır. Şekil 4'de gösterildiği gibi model eğitiminde veriler, normalleştirme katmanına girmeden çoklu dikkat katmanına girer [14]. Buradaki gizli katmandan çıkan verilere LoRA entegre edilir ve güncellenen model parametrelerinden çıkan veriler dikkat katmanına iletilir.



Şekil 4: LoRA Mimarisi


LoRA bu aşamada şunu gerçekler: U-Net'in aşağı iniş aşamasındaki dondurulan verilerin parametreleri güncellenir, yukarı çıkış aşamasında iki küçük matris haline getirilen parametreler çarpılır ve böylece veri çıkarımı tamamlanmış olur. Bir diğer ifadeyle çalışma mantığı, modelin ilk çözülme aşamasında giren verilerin dondurularak, var olan ağırlık matrisinin iki küçük matrise dönüşmesidir [4]. Normal akışta model, örneğin on bin parametre ile işlem yapacakken bu yaklaşımla birlikte (matris derecesi "bir" kabul edildiği takdirde) iki yüz parametreyle işlem yapacaktır. Bunun gerçek dünyadaki karşılığının milyonlarca parametre olduğu göz önünde tutulduğunda kayda değer bir vakit ve maliyet kazancıyla karşılaşılacaktır. Daha anlaşılır olabilmesi adına Şekil 5'de görselleştirilmiştir. LoRA, yalnızca bağımsız olarak değil birçok yöntemle entegre de çalışabilir. Bu da onu mevcut yaklaşımlara karşı esnek ve güçlü bir alternatif hâline getirir. Söz konusu avantajlar, LLM alanında PEFT yaklaşımlarının yaygınlaşmasına ve giderek artan bir ilgi görmesine neden olmaktadır.



Şekil 5: LoRA'nın Sayısal Görselleştirilmesi

3. Deneyler

Hizalaması oldukça başarılı olan DCI-VTON'da ellerdeki görünümün daha doğal ve gerçekçi hale getirilmesi için LoRA yöntemi kullanılmıştır. Önceki bölümlerde açıklanan parametre verimliliği ve eğitim süresi avantajları nedeniyle, bu çalışmada PEFT yöntemlerinden biri olan LoRA kullanılmıştır. Şekil 6'da blok diyagramı verilmiştir. Bu bölümde model eğitimi, yapılan deneyler ve çıkarımlar paylaşılmıştır.



Şekil 6: DCI-VTON'a LoRA Entegrasyonu Yapılması

3.1. Model Eğitimi

DCI-VTON'a LoRA entegre ederken tüm model yerine sadece küçük bir bölgeye odaklanılarak eğitim gerçekleştirilmiştir. Bunun için kohya_ss eğitim iskelet sistemi (framework) kullanılmıştır [15]. Modeli eğitmek için ilk olarak ön hazırlık yapılmıştır. Sadece üst bedenle ilgili görselleri barındıran Yüksek Tanımlı Sanal Deneme (High-Definition Virtual Try-On, VITON-HD) veri kümesi kullanılmıştır [16]. Bu verilerden ellerin olduğu daha küçük bir veri kümesi ve bunların siyah-beyaz ikili (binary) maskeleri oluşturulmuştur. Ardından LoRA eğitimi için gerekli parametrelerin olduğu kod blokları, modüler şekilde dikkat mekanizmalarına entegre edilmiştir. LoRA, sabit difüzyon (stable diffusion) tabanlıyken DCI-VTON sabit difüzyonu temel almamaktadır. Bu nedenle, aradaki bağlantıyı sağlayacak bir boru hattı (pipeline) devreye alınmıştır. Kohya_ss içerisindeki eğitim betiği, 385 orijinal manken veri sayısı ile eğitim adım sayısı 6000 olacak şekilde koşulmuştur. Bu veriler sonucunda devir sayısı (epoch) yaklaşık 62'ye tekabül etmektedir. Devir sayısı ise aşağıdaki gibi hesaplanmaktadır:

- $steps_per_epoch = data_size / batch_size$
- $epoch_count = max_train_steps / steps_per_epoch$

3.2. Çıkarımlar

Eğitim sonucunda elde edilen .safetensors uzantılı model ağırlıkları, çıkarım (inference) aşamasında kullanılmıştır. Çıkarımlar, orijinal manken ve maske verileri üzerinden gerçekleştirilmiştir. Modelin iki devir boyunca eğitilebilmesi amacıyla adım sayısı 18.000 olarak belirlenmiştir. Eğitimler, NVIDIA GeForce RTX 2080 Ti GPU (11 GB VRAM) ve 32 GB RAM donanımına sahip bir sistem üzerinde yürütülmüştür. Ancak bu değer, mevcut donanım kaynaklarını aşmış ve eğitim süreci sistem hatası nedeniyle sonlandırılmıştır. Adım sayısı 4500'e düşürüldüğünde ise Birleşik Hesaplama Aygıtı Mimarisi (Compute Unified Device Architecture, CUDA) belleğinin yetersizliği nedeniyle eğitim tamamlanamamıştır. Bu nedenle, kaynak yetersizliğinin ortaya çıkardığı sorunları aşmak ve eğitim sürecini tamamlayabilmek amacıyla eğitimde kullanılan görsel sayısı azaltılmıştır. 385 veri için sırasıyla 1500, 4500 ve 6000 adım sayılarıyla çıkarım sonuçları elde edilmiş, adım sayısı fazla olduğunda bu çıkarımların iyileştiği gözlenmiştir. Şekil 7'de soldan sağa doğru sırasıyla 9000 veriyle 1500 adımda, 385 veriyle 4500 adımda ve yine 385 veriyle 6000 adımda eğitilen modellerin çıkarım sonuçları paylaşılmaktadır. Sonuçlar, düşük veri miktarıyla dahi olsa yüksek adım sayısının daha gerçekçi görseller üretebildiğini göstermektedir.



Şekil 7: Inference Sonuçları (1500-4500-6000)

4. Sonuçlar

Kullanıcıların kıyafet deneme süreçlerini dijitalleştirme ve kolaylaştırma hedefiyle çıkılan bu yolda onlarca VTON çeşidine rastlanmıştır. Her yaklaşımın, önceki çalışmalarını baz alarak kendilerine göre yenilikler ürettiği görülmüştür. Bu süreç boyunca en doğru sonucu veren VTON çeşitleri gözlemlenip test edilmiştir. Yerel makinelerde MV-VTON, CAT-VTON, OOTDiffusion, IDM-VTON ve DCI-VTON projeleri koşulumaya çalışılmıştır. Bu çalışma için gerekli altyapının oluşturulması adına DCI-VTON kaynak alınmıştır. Projede, el bölgelerinde gözlemlenen yapısal bozulma problemlerine yönelik bir çözüm geliştirilmiştir. El bölgesine odaklanan bu çalışma, DCI-VTON'un gelişmiş hizalama kapasitesiyle tüm aşamalarda başarılı şekilde uygulanmıştır.

Şekil 8,9,10,11'de, LoRA entegrasyonu öncesi (sol taraftaki görseller) ve sonrası (sağ taraftaki görseller) model çıktıları karşılaştırmalı olarak sunulmuştur.



Şekil 8: LoRA Öncesi - Sonrası Karşılaştırma 1



Şekil 9: LoRA Öncesi - Sonrası Karşılaştırma 2



Şekil 10: LoRA Öncesi - Sonrası Karşılaştırma 3



Şekil 11: LoRA Öncesi - Sonrası Karşılaştırma 4

5. Tartışma

Bu çalışmada DCI-VTON tabanlı sanal giyim sistemlerinde el bölgesi görsel kalitesinin LoRA ile artırılması üzerine araştırmalar gerçekleştirilmiştir. Elde edilen çıktılar görsel kalite bağlamında nitel olarak değerlendirilmiştir. Yüksek adım sayısı ile yapılan eğitimlerdeki iyileşmelerin daha doğal, gerçekçi ve belirgin düzeyde olduğu tespit edilmiştir. Ellerin vücuda yakınlığı, parmakların belirginliği ve kıyafetle örtüşmesi modelin görsel iyileştirmesini kısıtlayarak bazı durumlarda değişimin sınırlı kalmasına yol açmıştır.

Bu duruma neden olan başlıca sınırlayıcı faktör, kullanılan donanım kaynaklarının yetersiz olması ve eğitim sürecinin ideal parametrelerle gerçekleştirilememesidir. Yapılan gözlemlerde eğitimde kullanılan veri sayısı yüksek olduğunda daha gerçekçi çıkarımlar yapıldığı görülmüştür. Ancak kaynak kısıtı nedeniyle eğitim süreci istenilen değerlerle yeterince test edilememiştir.

El gibi küçük bölgelerin eğitimi için ideal veri sayısı 1000–2000 aralığında olmakla birlikte, devir sayısının belirlenmesinde veri miktarı ve donanım kapasitesi göz önünde bulundurulmalıdır. Bununla birlikte, eğitimde çıkarımlar belirli bir adım sayısından sonra değişmemekte ve epoch artırıldığında da benzer sonuçlar alınabilmektedir. Çözüm olarak erken durdurma (early stopping) yöntemi uygulanabilir. Bu metot, validasyon kaybının (validation loss) kullanıcı tarafından belirlenen tanımlı bir eşiğe inmesi veya ardışık birkaç epoch iyileşme görülmemesi durumunda eğitim süreci otomatik olarak sonlandırır. Gelecek çalışmalarda daha güçlü donanım kaynaklarının kullanılması, parametre optimizasyonunun geliştirilmesi ve veri çeşitliliğinin artırılması, modelin el bölgesi görsel kalitesinde daha istikrarlı ve yüksek düzeyli sonuçlara ulaşılmasına katkı sağlayacaktır.

6. Kaynakça

- [1] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville ve Y. Bengio, “Generative adversarial networks,” *Communications of the ACM*, cilt 63, sayı 11, ss. 139–144, 2020.
- [2] J. Sohl-Dickstein, E. A. Weiss, N. Maheswaranathan ve S. Ganguli, “Deep Unsupervised Learning using Nonequilibrium Thermodynamics,” *arXiv:1503.03585*, 2015. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/1503.03585>
- [3] J. Gou, S. Sun, J. Zhang, J. Si, C. Qian ve L. Zhang, “Taming the power of diffusion models for high-quality virtual try-on with appearance flow,” *ACM MM*, ss. 7599–7607, 2023.
- [4] E. Hu, Y. Shen, P. Wallis ve diğerleri, “LoRA: Low-Rank Adaptation of Large Language Models,” *arXiv preprint arXiv:2106.09685*, 2021.
- [5] O. Ronneberger, P. Fischer ve T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” *MICCAI*, ss. 234–241, 2015.
- [6] D. Morelli, A. Baldrati, G. Cartella, M. Cornia, M. Bertini ve R. Cucchiara, “LadiVTON: Latent diffusion textual-inversion enhanced virtual try-on,” *arXiv preprint arXiv:2305.13501*, 2023.
- [7] R. Rombach, A. Blattmann, D. Lorenz, P. Esser ve B. Ommer, “High-Resolution Image Synthesis with Latent Diffusion Models,” *CoRR*, cilt abs/2112.10752, 2021.
- [8] J. Kim, G. Gu, M. Park, S. Park ve J. Choo, “Stable-VTON: Learning semantic correspondence with latent diffusion model for virtual try-on,” *arXiv preprint arXiv:2312.01725*, 2023.
- [9] Y. Xu, T. Gu, W. Chen ve C. Chen, “Ootdiffusion: Outfitting fusion based latent diffusion for controllable virtual try-on,” *arXiv preprint arXiv:2403.01779*, 2024.
- [10] H. Wang, Z. Zhang, D. Di, S. Zhang ve W. Zuo, “MV-VTON: Multi-View Virtual Try-On with Diffusion Models,” *arXiv:2404.17364*, 2024.
- [11] Y. Choi, S. Kwak, K. Lee, H. Choi ve J. Shin, “Improving Diffusion Models for Authentic Virtual Try-on in the Wild,” *arXiv preprint arXiv:2403.05139*, 2024.
- [12] Z. Chong, X. Dong, H. Li, S. Zhang, W. Zhang, X. Zhang, H. Zhao ve X. Liang, “CatVTON: Concatenation Is All You Need for Virtual Try-On with Diffusion Models,” *arXiv:2407.15886*, 2024. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/2407.15886>
- [13] B. Lester, R. Al-Rfou ve N. Constant, “The Power of Scale for Parameter-Efficient Prompt Tuning,” *CoRR*, cilt. abs/2104.08691, 2021. [Çevrimiçi]. Erişim: <https://arxiv.org/abs/2104.08691>
- [14] M. Quiros Bloch, L. Seyahi, and S. Ahmed, “Leveraging PEFT Strategies for Improved Performance and Efficiency in minBERT,” Stanford CS224N Default Project Report, Stanford University, 2024.
- [15] B. Maltais, “kohya_ss,” GitHub deposu, 2025. [Çevrimiçi]. Erişim: https://github.com/bmaltais/kohya_ss
- [16] X. Han, Z. Wu, Z. Wu, R. Yu ve L. S. Davis, “VITON: An image-based virtual try-on network,” *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 7543–7552, 2018.